

## Compréhension du projet et de la structure des données

Le laboratoire d'analyses fait face à un besoin d'automatisation d'un processus critique actuellement réalisé manuellement par les chimistes, à savoir l'interprétation des mesures issues d'un chromatographe en phase gazeuse couplé à un spectromètre de masse, abrégé en GC-MS. Lorsqu'un échantillon liquide est injecté, l'appareil sépare les molécules au fil du temps et mesure l'intensité de signaux correspondant à des fragments moléculaires précis, appelés rapports masse sur charge ou  $m/z$ . Ces signaux forment des courbes en cloche, appelées pics, dont la surface ou aire reflète la quantité de chaque composé chimique présent. Le défi consiste à transformer ces signaux bruts en données de concentration exploitables et fiables, tout en s'assurant que l'instrument de mesure ne dérive pas d'une analyse à l'autre.

Pour mener à bien ces analyses, le dossier zippé fourni, intitulé `cache_gam_sf`, s'articule autour de cinq lots distincts ou batchs correspondant à des campagnes de mesures réparties sur différentes périodes. Chaque batch se présente comme un répertoire regroupant des dossiers d'échantillons classés en deux catégories bien précises qui constituent le cœur de la démarche analytique. D'une part, les dossiers de type GAM représentent une gamme de huit solutions étalons aux concentrations croissantes et rigoureusement connues, indispensables pour établir la relation mathématique entre le signal et la quantité de matière. D'autre part, les dossiers de type SF regroupent deux à trois solutions de contrôle, préparées à des concentrations cibles fixes, qui servent à vérifier la validité de la méthode avant toute exploitation.

À l'intérieur de chaque dossier d'échantillon, l'organisation technique plonge directement au cœur de la mesure instrumentale à travers des fichiers précis. On y trouve une série de fichiers au format CSV, nommés selon le fragment surveillé sous la forme `mz_XXX.csv`, qui contiennent les données brutes de l'appareil sous forme de séries temporelles composées du temps de rétention en minutes et de l'intensité du signal mesuré par le spectromètre de masse. Chaque dossier d'échantillon s'accompagne également d'un fichier texte nommé `multiplier.txt`, qui consigne le facteur de dilution appliqué lors de la préparation de la solution, une information indispensable pour ajuster les calculs de concentration finale.

Enfin, le fichier `metadata.xlsx` complète l'archive en faisant office de table des matières analytique et de mode d'emploi de la méthode du laboratoire. Il formalise la nature de chaque composé chimique, qu'il s'agisse d'une molécule cible, d'un étalon interne ou d'un substitut, tout en associant chaque substance à ses fragments quantifiants et qualifiants. Ce fichier consigne également la correspondance essentielle entre chaque composé cible et son étalon interne deutéré de référence, garantissant ainsi que l'on dispose de toutes les clés de lecture indispensables pour interpréter correctement chaque signal brut contenu dans le zip.